التقنيات المعالجة المسبقة في اللغة الالة

معالجة البيانات المسبقة او (Data Preprocessing) من اهم الاشياء في الموديل لانو بتاثر بشكل كبير عل الكفاءة ودقة الموديل وقدرتو عل التعميم
فالبيانات الخام غالبا يتم جمعها بس مالها مكتملة بتكوم فيها تكرار واخطاء او اختلاف في المقاييس وقيم طرفية وبادي هاد الشيي عل نتائج غبر دقيقة شان هيك بنطبق بعض التقنيات لتنظيف البيانات قبل استخدامها لتعلبيم
وفي هاد التقرير رح نحكي عن

- اكتشاف القيم الطرفية
- (Feature Scaling)) مقياس الخصائص
- تقليل الابعاد
- معالجة القيم المفقودة
- ترميز المتغيرات الفئوية
- تحويل البيانات نحو التوزيع الطبيعي

أولا:القيم الطرفية (Outliers)

القيم الطرفية هي نقاط بيانات تختلف بشكل كبير عن باقي القيم في المجموعة البيانات ,قد تنتج هذه القيم عن اخطاء في الادخال او خلل في القياس

مثال:اذا كان عندي رواتب موظفين رواتبون تتراوح بين ال 300 و ال 1000 وظهرت قيمة ال 100000 فهي بتكون قيمة طرفية يعني قيم براالمجال وبتنزعلي المتوسط ووو

شو تأثيرها عل اداء المودل ؟؟
هيه بتاثر بشكل سلبي من خلال:

تشويه قيمة المتوسط الحسابي والانحراف المعياري
تأثير الكبير على عل نماذج الانحدار ما بعرف شو بعني
تقليل دقة التنبؤ
KNN التأثير عل الخوازميات المعتمدة عل المسافة مثل
بس ممكن القيم الطرفية تفيدي مو ضروري دائما احذفها

طرق اكتشاف القيم الطرفية:

1. طريقة Z-Score
تقيس هذة الطريقةع عدد الانحرافات المعيارية التي تبتعد بها القيمة عن المتوسط
المعالة
$z=(X-u)/q$

u المتوسط
q الانحراف المعياري

اذا كانت القيمة المطلقة ل
Z
اكبر من 3 فانها غالبا تعتبر قيمة طرفية
بنستخدم هيه الطريقة عندما تكون البيانات موزعة توزبعا طبيعيا تقريبا

ثانيا **(IQR) المدى الربيعي :**

مدى الربيعي هو الفرق بين الربع الثالث والربع الاول اي
q3 و q1
IQR=Q3-Q1
تعبتر القيم الطرفية اذا كانت اقل من

Q1-1.5(IQR)

او اكبر من
Q1+1.5(IQR)

بنستخدم هيه البيانات لما ما تكون موزعة توزيع طبيعي او تحوي عل انحراف

ثالثا(Boxplot) مخطط الصندوق:

هو تمثيل بياني يوضخ
الحد الادنى
الربع الاول
الوسيط
الربع الثالث
الحد الاقصى
واي نقطة خارج حدود الشعيرات تعتبر قيمة طرفية

طيب امتا بتحذف القيم الطرفية وامتا بنخليها ؟؟

بنحذفها اذا كانت ناتجة عن خطأ في الادخال او القياس
كانت تؤثر بشكل سلي واضح عل النموذج

نحتفظ فيها اذا
كانت تمثل ظاهرة حقيقية
كانت مهمة لتحليل الاعمال
كان الهدف هو اكتشاف الحالات الشاذة

(Feature Scaling) ثانيًا: مقياس الخصائص

يهدف مقياس الخصائص الى توحيد نطاق القيم بين متغيرات المختلفة لان بعض الخوارميات تتأثر بحجم القيم مثل
KNN

SVM
الشبكات العصبية
خوارزميات الانحدار باستخدام الانحدار التدريجي
واذا ما طبقنا هل المقياس فالمتغيرات الذات القيم الكبيرة رح تأثر اكثر من القيم القليلة

Min max Scaling
المعادلة

x_scaling =(X-Xmin)/(Xmax-Xmin)

تحويل القيم الى نطاق بين ال 0 و 1

بستخدمها عندما
لا توجد قيم طرفية كبيرة
نستخدم الشبكات العصبونية
نحتاج الى نطاق محدد
عيبها حساسة لقيم االطرفية

2. Standardization (التقييس)
المعادلة
X_Scaled=(X-u)/q
المتوسط u
الانحراف المعياريq
نسنخدم لما تكون البيانات موزعة طبيعيا

3. Robust Scaling

تعتمد على الوسيط والمدى الربيعي بدلا من المتوسط والانحراف المعياري

تستخدم عندما تكون القيم الطرفية كبيرة
البيانات منحرفة

ثالثًا: تقليل الأبعاد (Dimensionality Reduction)

هو تقليل عدد الخصائص او
(feauters)
مع الحفاظ على اكبر قدر ممكن من المعلومات

اهمية تقليل الابعاد

اول شي بخفف كثير وقت واستهلاك ذاكرة ورام لانو بتطلب كثير موارد ما بقدر شان هيك

(overfitting) تقليل خطر الافراط في التكيف
تقليل التكلفية الحسابية
معالجة مشكلة لعنة الابعاد

PCA تحليل المكونات الاساسية
principal Component Analysis

هو اسلوب احصائي يحول المتغيرات الاصلية المرتبطة الى متغييرات جديدة غير مرتبطة تسمى المكونات الرئيسية

خصائصه
المكون الاول يفسر اكبر نسبة من التباين
المكون الثاني يفسر تاني اكبر نسبة
المكونات متعامدة عل بعضها

خطوات الاساسية
توحيد البيانات
حساب مصفوفة التباين
استخراج القيم والمتجهات الذاتية
اختيار اهم مكونات
تحويل البيانات الى فضاء الجديد
يساعد ال
PCA
على الاحتفاظ بمعظم المعلومات مع تقليل الاخصائص

رابعًا: تقنيات معالجة إضافية

معال**جة القيم المفقودة**

وجود قيم مفقودة قد يؤدي الى نتائج غير دقيقة

طرق المعالجة

حذف الصفوف التي تحتوي عل قيم مفقودة
التعويض بالمتوسط او الوسيط
التعويض بالمنوال
استخدام نماذج تنبؤ للقيم المفقودة

ترميز المتغيرات الفئوية
لا يستطيع الموديل التعامل مع النصوص مباشرة لذلك
1. الترميز العددي (Label Encoding)
يحول الفئات الى ارقام
مناسب للمتغيرات الترتيبية
ضعيف متوسط ممتاز

2. الترميز الأحادي (One-Hot Encoding)
ينشئ عامود منفصل لكل فئة

مناسب للمتغيرات التي لا تحوي عل ترتيب

أساليب المعاينة (Sampling Methods)
بستخدما لما ما يكون في توازن في الفئات

1. الإفراط في المعاينة (Over-Sampling)

زيادة عدد البيانات الفئة الاكبر
SMOTE مثل تقنية

2. التقليل من المعاينة (Under-Sampling)
تقليل عدد بيانات الفئة الاكبر
الميزة سرعة التدريب
العيب فقدان بعض المعلومات

خامسًا: تحويل البيانات نحو التوزيع الطبيعي
عديد من الخوارزميات تفترض ان البيانات موزعة توزيعا طبيعيا
فوائد التوزيع الطبيعي
تثبيت التباين
تقليل الانحراف
تفليل تاثير القيم الطرفية
تحسين دقة النماذج الاحصائية

الخوارزميات التي تستفيد
الانحدار الخطي
الانحدار اللوجستي
نماذج نايف بايز

طرق التحويل

التحويل اللوغاريتمي

الجذر التربيعي
box cox تحويل

الخاتمة
تعد معالجة البيانات المسبقة اهم المراحل واساسية في بناء النموذج
فالتعامل الصحيح مع القيم الطرفية وتوحيد المفاييس وتقليل الابعاد ومعالجة القيم الطرفية وترميز المتغيرات المئوية وموازنة البيانات وتحويلها الى توزيع طبيعي
كلها عوامل تؤدي الى تحسين جودة البيانات ودقة النموذج ونجاح اي نموذج يعتمد عل جودة البيانات التي اتدرب عليها

المراجع

1. Pattern Recognition and Machine Learning – 2006 ،كريستوفر بيشوب.
2. The Elements of Statistical Learning – 2009 ،هاستي وتيبشيراني وفريدمان.
3. An Introduction to Statistical Learning – 2013 ،جيمس وآخرون.