Part 1: Recommendation Systems: Uncovering Hidden Patterns through Unsupervised Learning

1. Introduction: Recommendation Systems as Unsupervised Learning

انظمة التوصية هي خوارزمية مصممة لاقتراح عناصر افلام منتجات اغاني تهم المستخدم ورغم ان بعض النماذج تستخدم التعلم الخاضع
(Supervised Learning)
الا ان جوهر العديد من محركات التوصية يعمل كاسلوب تعلم غير خاضع لاشراف
(unSupervised Learning)
في هذا النوع من التعلم لا يتم تزويد النموذج ب اجابات صحيحة مسبقة بل يقوم باكتشاف البيانات وبقدر يطلع باتن منون واضح والعلاقات بين البيانات واوجه الاختلاف والتشابه من خلال تجميع البيانات المتشابها في كلاستر واحد او جساب المسافات الرياضية بين العناصر يمكن لهذا الانظمة التبؤء بما قد يعجب المستخدم دون الحاجة لتعليمات صريحة حول ماهية "التوصية "الجيدة

2. Real-World Applications

انظمة التوصية هي محرك الخفي لزيادة تفاعل المستخدمين في كبرى الشركات التقنية

Netflix:
تقترح الافلام والمسلسات من خلال تحليل سجل المشاهدة الخاص بك الانواع التي
تفضلها وما يستمع يه المستخدمون الذين لديهم عادات مشاهدة متشابهة لعاداتك
Spotify
تشغل ميزات مثل
discover weekly
عبر تحليل الخصائص الصوتية لاغاني
(الايقاع والنغمة)
ومقاطعتها مع ملايين القوائم الموسيقية للمستخدمين
Amazon:
تستخدم محركات التوصية لزيادة المبيعات
مثال
Customer who bought this item also bought
ويعتمد بشكل كبير على تحليل سجلات الشراء وسلوك التصفح

3. Content-Based Filtering

How to works :
يقوم هذا النهج بالتوصية بعناصر مشابهة لتلك التي اعجبت المستخدم في الماضي ويعتمد كليا عل الخصائض العناصر نفسها
عل سبيل المثال اذا كانت تشاهد الكثير من افلام الخيال العلمي
.من إخراج "كريستوفر نولان"، فسيقوم النظام باقتراح أفلام خيال علمي أخرى أو أفلام لنفس المخرج

Strengths

No Item Cold-Start:

اذا تمت اضافة فيلم جديد لقاعدة البيانات يمكن التوصية به فورا بناء على بياناته الوصفية النوع ,طاقم العمل
حتى لو لم يقم احد بتقييمه بعد

Transparency:

من السهل ان تشرح للمستخدم لماذا تم اقتراح هذا العنصر مثلا لانك شاهدت فيلم...

Weaknesses:

Lack of Serendipity

يميل النظام الى حصر المستخدم في فقاعة حيث يقترح فقط ما يعرفه المستخدم مسبقا ,وبفشل في تقديم عناصر جديدة كليا خارج ملفه الشخصي المعتاد

:When to use

تعتبر الافضل للمنصات التي تكون فيها خصائص العناصر غنية وواضحة مثل المقالات الاخبارية والمدونات او كتالوجات منتجات محددة

4. Collaborative Filtering

how to work

تتجاهل التصفية التعاونية المحتوى الفعلي للعناصر مثل نوع الفيلم او المخرج وتعتمد بدلا من ذلك عل التفاعلات والسلوكيات التاريخية لجميع المستخدمين الفكرة الاساسية هي اذا اتفق مستخدمان في تقييم عناصر معينة في الماضي فانهما سيفقان عل العناصر اخرى في المستقبل

:يوجد منها نوعان رئيسيان

1 User-Based Collaborative Filtering:

تبحث عن مستخدمين يشبهونك اذا كان المستخدم أ
والمستخدم ب يحبان الافلام
X and Y and Z
وكان المستخدم أ يحب ايضا الفيلم
W
فسيقوم النظام باقتراح الفيلم
W
للمستخدم ب

2 Item-Based Collaborative Filtering:

تبحث عن التشابه بين العناصر بناء عل تقييمات المستخدمين
اذا كان المستخدمون يميلون الى اعطاء تقييمات متشابهة للعنصر
أ و العنصر
ب قان اي شخص يعجبه العنصر أ
سيتم التوصية بالعنصر ب له

Strengths:

Serendipity:

يمكنها تقديم انواع او فئات جديدة كليا للمستخدم لم يكن ليستكشفها بنفسه طالما ان المستخدمين المتشابهين له قد احبوها

No Domain Knowledge Required:

لا يحتاج النظام لمعرفة اي تفاصيل عن العناصر نفسها بل يحتاج فقط الى مصفوفة تفاعلات المستخدمين مع العناصر

Weaknesses:

Cold-Start Problem

لا يكمن التوصية بعناصر جديدة ليس لها تقييمات بعد ولا يمكن تقديم توصيات دقيقة لمستحدم جديد كليا

Sparsity:

في القواعد البيانات الضخمة يقييم معظم المستخدمين جزءا صغيرا جدا من العناصر مما يجعل مصفوفة التفاعلات فارغة بنسبة كبيرة وصعبة التحليل

When to use:

الافضل للمنصات التي تمتلك قاعدة مستخدمين ضخمة وحجما كبيرا من التفاعلات مثل مواقع التجارة الالكترونية

5. The Mathematical Core: Cosine Similarity

يعتمد كلا النهجين غالبا عل قياس المسافة او التشابه بين المتجيهات
vectors
باستخدام مقاييس رياضية من التعلم غير الخاضع لاشراف واشهرها التشابه بجيب التمام

$$similarity=\cos(\theta)=\| A\| \| B\| /A\cdot B$$

Part 2: Jupyter Notebook Implementation Concepts or colob notebook

Step 1: Data Processing

رح نستخدم بيانات مصغرة مثل مجموعة بيانات
movielens
بيكون عندك جدولين جدول افلام يحوي عل اسم الفلم وتصنيفه وجدول للتقييمات يحتوي عل رقم المستخدم رقم الفيلم وتقييمه

Step 2: Content-Based Filtering Approach

تاخوذ عامود تصنيفات الافلام
TF-IDF نحوله لمصفوفة ارقام باستخدام تقنية
لكي يفهمها الكمبيوتر

تحسب التشابه بين الافلام بناء عل هذه المصفوفة باستخدام معادلة.(Cosine Similarity)
النتيجة عند طلب توصية لفيلم اكشن وخيال علمي مثل
the matrix
سيبحث النظام عن اقرب فيلم يحمل نفس هذه التصينفات ويقترحه

Step 3: Collaborative Filtering (Item-Based)

هنا نتجاهل التصينيف تماما
pivot table ننشئ جدولا
يجمع المستخدمين كصفوف والافلام كاعمدة والقيم هي التقييمات

نحسب التشابه بين اعمدة افلام نبحث عن افلام التي تم تقييمها معا بشكل عالي من نفس الاشخاص
نحسب التشابه بين الاعمدة الافلام نبحث عن الافلام التي تم تقييمها معا بشكل عالي من نفس الاشخاص
toy story النتيجة اذا كان المستخدمون الذين احبو فيلم
shrek يحبون ايضا فيلم
Toy story فسيقترح النظام هذا الفيلم لاي شخص جديد يشاهد
حتى لو لم يكن النظام يعرف انهما افلام رسوم متحركة

Evaluation

Content-Based:
نجح لانه ربط الافلام بناء عل الخصائص المكتوبة التصنيف
Collaborative
نجح في اكتشاف العلاقات المخفية بين الافلام بناء عل الذوق الناس المشترك بدون اي تدخل او تصنيف مسبق

هلق ملخص البحث بيحكي باختصار عم الخوزميات الذكية الاتي بتقتلرحلك شغلات عل ذوقك مثل نتفليكس لما يقترحلك مسلسل او يوتوب لما يشغلك فيديو ورا فيديو او امازون لما يقترحلك منتجات
الفكرة الاساسية بالبحث هيه كيف هالانظمة بتفهم ذوقك وتشتغل لحالها بدون ما حدا يبرمجها خطوة بخطوة وتقولها هاد الفيلم بيشبه هاد الفيلم وهاد الي بنسميه بالذكاء الاصطناعي التعلم غير خاضع لاشراف
هيه بس بتراقب كميات ضخمة من البيانات وبتكتشف الانماط المخفية والروابط بينها لحالها
:البحث بيشرح طريقتين أساسيتين بتستخدمهم هالشركات لتعرف شو رح يعجبك

بتعتمد على صفات الشغلة نفسها. يعني إذا شفتك عم تحضر **:(Content-Based - التصفية بالمحتوى) الطريقة الأولى**
.أو تقرأ عن لغة بايثون، النظام فوراً رح يقترحلك مقالات أو كورسات بايثون تانية، لأنه قارن "محتوى" الشغلات ببعضها

- هون النظام ما بيهمه محتوى الشغلة أبداً، بيهمه **:(Collaborative - التصفية التعاونية) الطريقة التانية**

"تصرفات الناس". بيشوف إنك أنت وشخص تاني عندكم نفس الذوق تماماً. فإذا هاد الشخص شاف شيء جديد
.وعجبه، النظام فوراً رح يقترحه إلك، لأنه اكتشف إنكم بتشبهوا بعض بالذوق بغض النظر عن شو هو هاد الشيء

مثال حلو ومختصر مثلا تخيل عل منصة كورسات في
كورس بايثون
كورس تنظيف بيانات
كورس اتمتة
كورس ايطالي

الطريقة الاولى التصفية بالمتحوى
يعني مثلا انت حضرت بايثون
: كيف بفكر النظام
tags النظام بيقرا وصف الكورس وبشوف الكلمات المفتاحية و
مثل برمجة كود بايثون ووو
بيرةق بدور بل القاعدة البيانات عل كورسات فيها نفس الكلمات فبلاقي كورس تنظيف بيانات لان مرتبط بل البايثون والبرمجة بروح بيقترحلك ياه
.الخلاصة: النظام هون فهم "**محتوى**" الكورس وقارنه مع محتوى الكورسات التانية

(Collaborative Filtering) الطريقة الثانية: التصفية التعاونية
انت حضرت كورس بايثون وكورس اتمتة

: كيف بيفكر النظام
اعمى عن المحتوى ما بيعرف شو يعني بايثون وشو يعني اتمتة هو بيراقب الناس بيشوف في شخص تاني اسمو احمد مثلا
git حضر بايثون وكورس اتمتة وكمان حضر كورس ثالث
git النظام بيلاحظ النمط التالي هذا المستخدم واحمد عندهم نفس الذوق والتصرفات بالضبط وبما ان احمد شاف كورس وعجبه فاحتمال كبير جدا يعجبك انت كمان فبيقترحلك ياه
.الخلاصة: النظام هون اقترحلك بناءً على "تشابهك مع تصرفات مستخدم تاني"، مو بناءً على تفاصيل الكورس نفسه